




統計力学と機械学習

統計力学/イジング模型の概要と
関連した機械学習(ボルツマンマシン)について


統計力学とは？

＝統計的な視点から系の熱力学を記述

ミクロな世界




統計的視点



熱力学の世界

気体/磁石/金属など



統計力学の概要

- 温度 T において i 番目のエネルギー E_i の状態が実現する確率 p_i
- 熱力学量は確率分布の期待値で与えられる(k_B :ボルツマン定数)


$$p_i = \frac{\exp(-E_i/k_B T)}{Z} \quad \langle E \rangle = \sum_i E_i p_i$$

- 確率分布の規格化定数 Z : 分配関数
- 自由エネルギー F は分配関数の対数

$$Z = \sum_i \exp(-E_i/k_B T) \quad F = k_B T \ln Z$$

簡単な例：2 状態系

- $\sigma_1, \sigma_2 = \pm 1$ の値をとる 2 つの自由度があり、同じ値をとるとエネルギー E が下がる




$\sigma_1, \sigma_2 = \pm 1 \quad E = -J\sigma_1\sigma_2 \quad (J > 0)$

- 4 通りの状態($\{++,+,-,-,--\}$)について、それぞれ確率を求める

簡単な例：2 状態系

- $\sigma_1, \sigma_2 = \pm 1$ の値をとる 2 つの自由度があり、同じ値をとるとエネルギー E が下がる



A diagram showing two blue circles, each containing a symbol σ_1 and σ_2 respectively. A red line connects the two circles, representing an interaction between the spins.

$$\sigma_1, \sigma_2 = \pm 1 \quad E = -J\sigma_1\sigma_2 \quad (J > 0)$$

- 4 通りの状態($\{++,+,-,-,--\}$)について、それぞれ確率を求める

$$K \equiv \frac{J}{k_B T} \quad Z = \exp(K) + \exp(-K) + \exp(-K) + \exp(K) = 4 \cosh(K)$$


$$p_{++} = \frac{\exp(-K)}{Z} (= p_{--}) \quad p_{+-} = \frac{\exp(K)}{Z} (= p_{-+})$$

$$\langle E \rangle = -J * p_{++} + J * p_{+-} + J * p_{-+} - J * p_{--} = -J \tanh(K)$$

統計力学の代表例：イジング模型

- 格子上的点に変数(スピン) $\sigma = \pm 1$ を与える
 - 磁石のモデル(前のスライドの系を複雑にしたもの)
- 系全体のエネルギー
 - J_{ij} : 結合定数, h_k : 外部磁場
 - i, j, k はサイトのindex


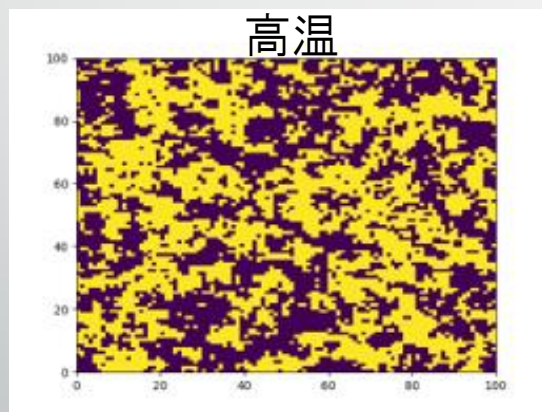
$$E = - \sum_{ij} J_{ij} \sigma_i \sigma_j - \sum_k h_k \sigma_k$$



統計力学の代表例：イジング模型

$$E = - \sum_{ij} J_{ij} \sigma_i \sigma_j - \sum_k h_k \sigma_k$$

- J, h, Tのパラメーターから、確率分布が定まる
 - ※実際はモンテカルロ法などで近似的に計算
- 確率分布に従って系の配位 (≡ 2 値画像) が生成




例) 相互作用が一樣かつ正 ($J_{ij}=J>0$) なら、高温ではスピン変数はバラバラで、低温では値が揃う

計算例：温度vs比熱

(マルコフ連鎖モンテカルロ法で計算：卒業研究)

比熱



温度


N：系の一边の大きさ
($J_{ij}=J>0$, $h_k=0$)

機械学習での対応物：ボルツマンマシン

互いに結合したノードから構成
ノードは変数 $v=0$ or 1 を持つ
ノード間にバイアス b と重み W が定義

概要：

- 未知の確率分布 Q から出力されたデータ列 $X = \{X_1, X_2, \dots\}$ を入力として、 Q を推定。
- バイアス/重みを調節して、 Q に近い確率分布 Q' を作る




機械学習での対応物：ボルツマンマシン

- 互いに結合したノードから構成
- ノードは変数 $v=0$ or 1 を持つ
- ノード間にバイアス b と重み W が定義

“エネルギー”: Φ

$$\Phi[\mathbf{v}] = - \sum_{ij} w_{ij} v_i v_j - \sum_k b_k v_k$$


$$p(\mathbf{v}) = \frac{1}{Z} \exp(-\Phi[\mathbf{v}]) \quad Z = \sum_{\mathbf{v}} \exp(-\Phi[\mathbf{v}])$$





イジング模型 \Leftrightarrow ボルツマンマシン

$$\{J_{ij}, h_k\}$$

既知



分布 $\{p\}$




生成物

- 統計力学にインスパイアされた学習の手法も多い
(ex, 平均場近似, モンテカルロ法)



イジング模型 \Leftrightarrow ボルツマンマシン

$\{w_{ij}, b_k\}$

推定



分布 $\{p\}$

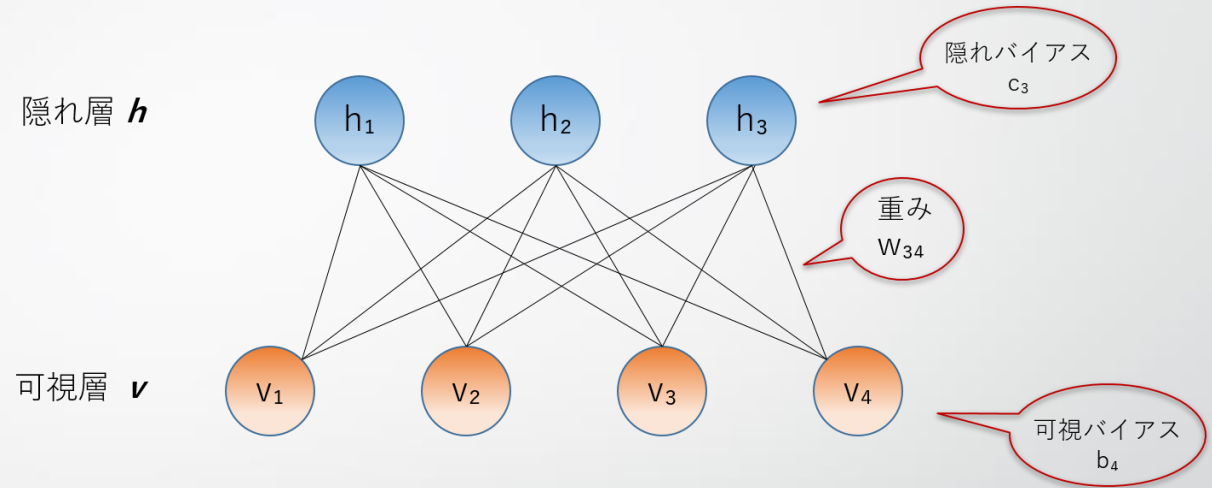


入力データ

- 統計力学にインスパイアされた学習の手法も多い
(ex, 平均場近似, モンテカルロ法)

応用例：制限付きボルツマンマシン(RBM)


- 隠れ層と可視層に分け、
可視層と隠れ層の間でのみ結合



$$\Phi[v, h] = - \sum_{ij} w_{ij} v_i h_j - \sum_k b_k v_k - \sum_k c_k h_k$$


計算例：MNISTを用いた自己符号化

- 1. MNISTの画像を10000個ランダムにRBMの可視層に入力し、学習
 - CD法(contrastive divergence)



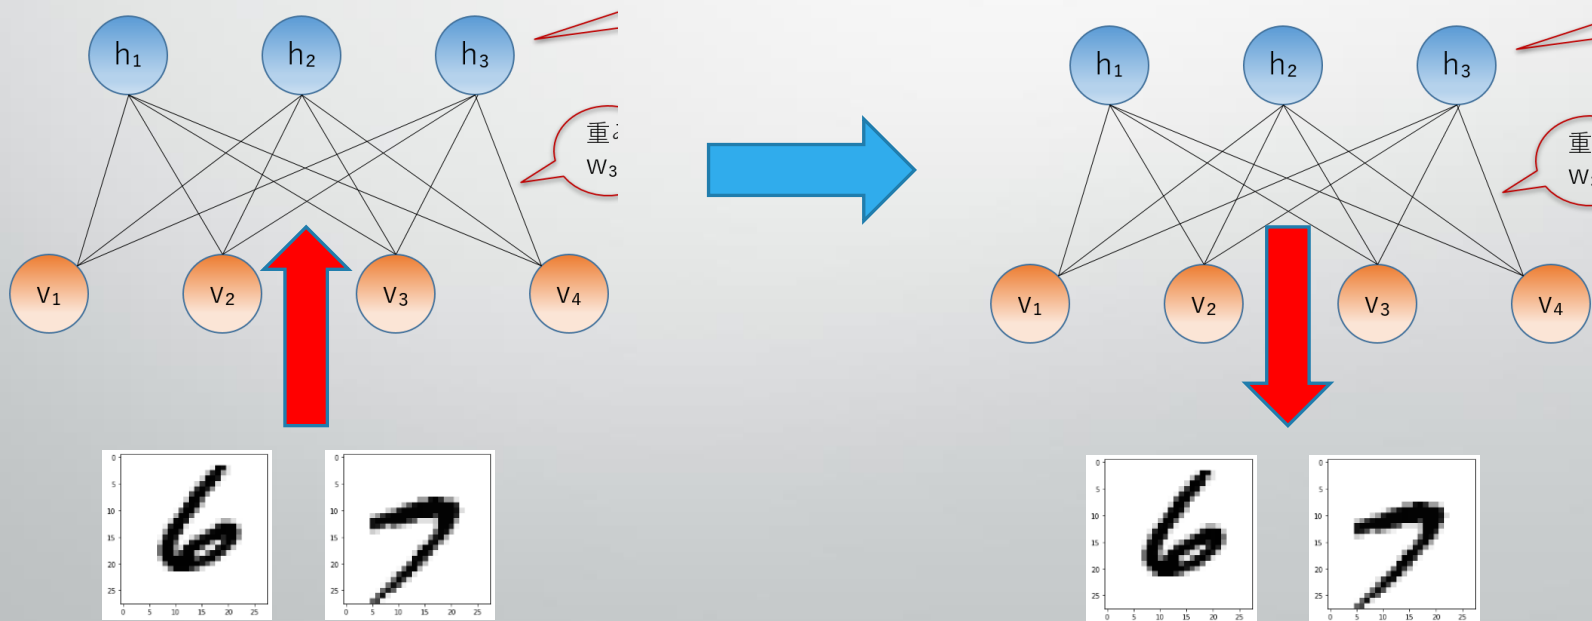
計算例：MNISTを用いた自己符号化

- 1. MNISTの画像を10000個ランダムにRBMの可視層に入力し、学習
- 2. 学習後、可視層に画像を入力して隠れ層の出力を得る







計算例：MNISTを用いた自己符号化

- 1. MNISTの画像を10000個ランダムにRBMの可視層に入力し、学習
- 2. 学習後、可視層に画像を入力して隠れ層の出力を得る
- 3. 得られた隠れ層の出力で、再度可視層の値を出力



計算結果：MNISTを用いた自己符号化

MNIST



生成された
画像

